ATE / Semantic-k 错误归因 · 错误案例 · 01/16

001020372 | ChooseAttr

Is the zebra to the left of the bench black or white?



原始图片：等比显示，不裁剪

Gold
white

All-Writer [correct]
White

Semantic-k [wrong]
Black

Question-Last-k [wrong]
Black

Q-Random 20261103 [wrong]
Black

Q-Random 20261107 [correct]
White

Q-Random 20261111 [wrong]
Black

k / R = 11 / 33 = 33.33% · Question Tokens = 16 · P-1 = 614

图像不重叠确认子集：否（用户指定的必含案例）；核心预算缩减 0 Token；位置均为 0-based。

已选 Semantic | 未选 Question | 未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	Is 583 / n=1	the 584 / n=1	zebra 585,586,587 / n=3	to 588 / n=1	the 589 / n=1	left 590 / n=1	of 591 / n=1	the 592 / n=1	bench 593,594 / n=2	black 595 / n=1	
or 596 / n=1	white 597 / n=1	? 598 / n=1	[newline] 599 / n=1	Answer 600 / n=1	the 601 / n=1	question 602 / n=1	using 603 / n=1	a 604 / n=1	single 605 / n=1	word 606 / n=1	or 607 / n=1	phrase 608 / n=1
. 609 / n=1	ASSISTANT 610,611,612,613 / n=4											

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

关系词 left、of、选择连接词 or 和两个颜色选项都已选中；不能把这道错题解释成漏选这些词。遗漏的是 Is、三个 the 和问号，且整个指令/模板均未读图。是否由功能词或边界接收位置造成，尚无补词验证。

冻结的单组候选：? @[598]；Answer @[600]；ASSISTANT @[610, 611, 612, 613]；Is @[583]；the @[584]；the @[589]

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

ATE / Semantic-k 错误归因 · 错误案例 · 02/16

14236062 | ChooseAttr

Does the bathtub look black or cream colored?



原始图片：等比显示，不裁剪

Gold
cream colored

All-Writer [correct]
Cream colored

Semantic-k [wrong]
Black

Question-Last-k [correct]
Cream colored

Q-Random 20261103 [correct]
Cream colored

Q-Random 20261107 [correct]
Cream colored

Q-Random 20261111 [wrong]
Black

k / R = 7 / 29 = 24.14% · Question Tokens = 12 · P-1 = 610

图像不重叠确认子集：是；核心预算缩减 2 Token；位置均为 0-based。

已选 Semantic | 未选 Question | 未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	Does 583 / n=1	the 584 / n=1	bathtub 585,586,587 / n=3	look 588 / n=1	black 589 / n=1	or 590 / n=1	cream 591,592 / n=2	colored 593 / n=1	? 594 / n=1	[newline] 595 / n=1
Answer 596 / n=1	the 597 / n=1	question 598 / n=1	using 599 / n=1	a 600 / n=1	single 601 / n=1	word 602 / n=1	or 603 / n=1	phrase 604 / n=1	. 605 / n=1	ASSISTANT 606,607,608,609 / n=4	

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

or 与 colored 是词法核心候选，却因整词后缀对照的可行预算缩减而未进入 Semantic-k。cream 已选中但 Gold 是 cream colored；可能同时存在选项连接与答案表面形式问题，尚不能确定哪个遗漏有因果作用。

冻结的单组候选：? @[594]；Answer @[596]；ASSISTANT @[606, 607, 608, 609]；or @[590]；Does @[583]；the @[584]

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

ATE / Semantic-k 错误归因 · 错误案例 · 03/16

02760157 | ChooseCat

Are these penguins or panda bears?



原始图片：等比显示，不裁剪

Gold
panda bears

All-Writer [correct]
Panda bears

Semantic-k [wrong]
Panda

Question-Last-k [correct]
Panda bears

Q-Random 20261103 [correct]
Panda bears

Q-Random 20261107 [correct]
Panda bears

Q-Random 20261111 [correct]
Panda bears

k / R = 9 / 28 = 32.14% · Question Tokens = 11 · P-1 = 609
图像不重叠确认子集：是；核心预算缩减 0 Token；位置均为 0-based。

已选 Semantic | 未选 Question | 未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	Are 583 / n=1	these 584 / n=1	penguins 585,586,587 / n=3	or 588 / n=1	panda 589,590 / n=2	bears 591,592 / n=2	? 593 / n=1	[newline] 594 / n=1	Answer 595 / n=1
the 596 / n=1	question 597 / n=1	using 598 / n=1	a 599 / n=1	single 600 / n=1	word 601 / n=1	or 602 / n=1	phrase 603 / n=1	. 604 / n=1	ASSISTANT 605,606,607,608 / n=4	

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

penguins、or、panda、bears 全部已选。Semantic 输出 Panda，官方 Gold 为 panda bears；冻结评分器严格判错，但这不等于已经识别成错误动物。此例必须单独标注答案表面形式不匹配，不能全归因于视觉接收失败。

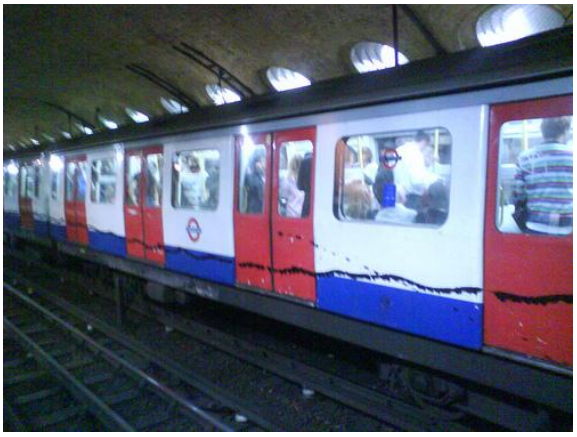
冻结的单组候选：? @[593]；Answer @[595]；ASSISTANT @[605, 606, 607, 608]；Are @[583]

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

ATE / Semantic-k 错误归因 · 错误案例 · 04/16

09662582 | ChooseCat

Is this a truck or a train?



原始图片：等比显示，不裁剪

Gold
train

All-Writer [correct]
Train

Semantic-k [wrong]
Truck

Question-Last-k [correct]
Train

Q-Random 20261103 [wrong]
Truck

Q-Random 20261107 [wrong]
Truck

Q-Random 20261111 [wrong]
Truck

k / R = 4 / 26 = 15.38% · Question Tokens = 9 · P-1 = 607

图像不重叠确认子集：是；核心预算缩减 1 Token；位置均为 0-based。

已选 Semantic | 未选 Question | 未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	Is 583 / n=1	this 584 / n=1	a 585 / n=1	truck 586,587 / n=2	or 588 / n=1	a 589 / n=1	train 590 / n=1	? 591 / n=1	[newline] 592 / n=1	Answer 593 / n=1

the 594 / n=1	question 595 / n=1	using 596 / n=1	a 597 / n=1	single 598 / n=1	word 599 / n=1	or 600 / n=1	phrase 601 / n=1	. 602 / n=1	ASSISTANT 603,604,605,606 / n=4

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

train 是问题中的视觉类别选项，却因可行预算缩减而被删除；this、truck、or 已选。该输入规则产生了一个很具体的漏选候选，但补回 train 是否能纠正 Truck 尚未测试。

冻结的单组候选：? @[591]；Answer @[593]；ASSISTANT @[603, 604, 605, 606]；Is @[583]；a @[585]；train @[590]

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

08163732 | ChooseRel

Is the man to the left or to the right of the boy that is wearing a coat?



Gold
right

All-Writer [correct]
Right

Semantic-k [wrong]
Left

Question-Last-k [correct]
Right

Q-Random 20261103 [wrong]
Left

Q-Random 20261107 [correct]
Right

Q-Random 20261111 [correct]
Right

原始图片：等比显示，不裁剪

k / R = 12 / 37 = 32.43% · Question Tokens = 20 · P-1 = 618
图像不重叠确认子集：是；核心预算缩减 0 Token；位置均为 0-based。

已选 Semantic | 未选 Question | 未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	Is 583 / n=1	the 584 / n=1	man 585 / n=1	to 586 / n=1	the 587 / n=1	left 588 / n=1	or 589 / n=1	to 590 / n=1	the 591 / n=1	right 592 / n=1	of 593 / n=1
the 594 / n=1	boy 595 / n=1	that 596 / n=1	is 597 / n=1	wearing 598,599 / n=2	a 600 / n=1	coat 601 / n=1	? 602 / n=1	[newline] 603 / n=1	Answer 604 / n=1	the 605 / n=1	question 606 / n=1	
using 607 / n=1	a 608 / n=1	single 609 / n=1	word 610 / n=1	or 611 / n=1	phrase 612 / n=1	. 613 / n=1	ASSISTANT 614,615,616,617 / n=4					

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

left、right、of、boy、wearing、coat 等关系及对象锚点均已选。遗漏主要为系动词、冠词与问号；左右判断仍出错说明有关键内容词不等于视觉定位必然正确。

冻结的单组候选：? @[602]；Answer @[604]；ASSISTANT @[614, 615, 616, 617]；Is @[583]；the @[584]；a @[600]

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

15260602 | ChooseRel

Is the car to the left or to the right of the train car?



原始图片：等比显示，不裁剪

Gold
right

All-Writer [correct]
Right

Semantic-k [wrong]
Left

Question-Last-k [wrong]
Left

Q-Random 20261103 [wrong]
Left

Q-Random 20261107 [wrong]
Left

Q-Random 20261111 [wrong]
Left

k / R = 9 / 32 = 28.12% · Question Tokens = 15 · P-1 = 613
图像不重叠确认子集：是；核心预算缩减 0 Token；位置均为 0-based。

已选 Semantic | 未选 Question | 未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	Is 583 / n=1	the 584 / n=1	car 585 / n=1	to 586 / n=1	the 587 / n=1	left 588 / n=1	or 589 / n=1	to 590 / n=1	the 591 / n=1	right 592 / n=1	of 593 / n=1
the 594 / n=1	train 595 / n=1	car 596 / n=1	? 597 / n=1	[newline] 598 / n=1	Answer 599 / n=1	the 600 / n=1	question 601 / n=1	using 602 / n=1	a 603 / n=1	single 604 / n=1	word 605 / n=1	or 606 / n=1
phrase 607 / n=1	. 608 / n=1	ASSISTANT 609,610,611,612 / n=4										

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

left/right、两个方向连接及 train car 均已选。不能预设漏了方向词；功能词和模板接收位置是待检验候选，也可能存在多个位置的共同作用。

冻结的单组候选：? @[597]；Answer @[599]；ASSISTANT @[609, 610, 611, 612]；Is @[583]；the @[584]；the @[587]

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

01445490 | CompareAttr

What is common to the shield and the bat?



原始图片：等比显示，不裁剪

Gold
color

All-Writer [correct]
Color

Semantic-k [wrong]
Material

Question-Last-k [wrong]
Material

Q-Random 20261103 [wrong]
Eye

Q-Random 20261107 [correct]
Color

Q-Random 20261111 [correct]
Color

k / R = 6 / 27 = 22.22% · Question Tokens = 10 · P-1 = 608

图像不重叠确认子集：是；核心预算缩减 0 Token；位置均为 0-based。

已选 Semantic | 未选 Question | 未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	What 583 / n=1	is 584 / n=1	common 585 / n=1	to 586 / n=1	the 587 / n=1	shield 588 / n=1	and 589 / n=1	the 590 / n=1	bat 591 / n=1	? 592 / n=1	[newline] 593 / n=1
Answer 594 / n=1	the 595 / n=1	question 596 / n=1	using 597 / n=1	a 598 / n=1	single 599 / n=1	word 600 / n=1	or 601 / n=1	phrase 602 / n=1	. 603 / n=1	ASSISTANT 604,605,606,607 / n=4		

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

What、common、shield、and、bat 已选，输出却从 Gold Color 变为 Material。比较/共性任务的目标属性发生变化，但不能仅凭答案推断视觉表示缺失；is、冠词、问号及模板是否有作用仍未验证。

冻结的单组候选：? @[592]；Answer @[594]；ASSISTANT @[604, 605, 606, 607]；is @[584]；the @[587]；the @[590]

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

ATE / Semantic-k 错误归因 · 错误案例 · 08/16

12951806 | CompareAttr

What do the container and the plate have in common?



原始图片：等比显示，不裁剪

Gold
color

All-Writer [correct]
Color

Semantic-k [wrong]
Material

Question-Last-k [correct]
Color

Q-Random 20261103 [correct]
Color

Q-Random 20261107 [correct]
Color

Q-Random 20261111 [correct]
Color

k / R = 6 / 28 = 21.43% · Question Tokens = 11 · P-1 = 609

图像不重叠确认子集：是；核心预算缩减 0 Token；位置均为 0-based。

已选 Semantic | 未选 Question | 未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	What 583 / n=1	do 584 / n=1	the 585 / n=1	container 586 / n=1	and 587 / n=1	the 588 / n=1	plate 589 / n=1	have 590 / n=1	in 591 / n=1	common 592 / n=1	? 593 / n=1
[newline] 594 / n=1	Answer 595 / n=1	the 596 / n=1	question 597 / n=1	using 598 / n=1	a 599 / n=1	single 600 / n=1	word 601 / n=1	or 602 / n=1	phrase 603 / n=1	. 604 / n=1	ASSISTANT 605,606,607,608 / n=4	

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

What、container、plate、in、common、and 均已选。do、have 被 STOP 规则排除，可能影响提问形式的接收，但 Material 与 Color 的变化并不能单独证明这种解释。

冻结的单组候选：? @[593]；Answer @[595]；ASSISTANT @[605, 606, 607, 608]；do @[584]；have @[590]；the @[585]

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

0160501 | LogicalObj

Do you see a door or a window that are open?



原始图片：等比显示，不裁剪

Gold
yes

All-Writer [correct]
Yes

Semantic-k [wrong]
Door

Question-Last-k [correct]
Yes

Q-Random 20261103 [wrong]
Door

Q-Random 20261107 [correct]
Yes

Q-Random 20261111 [correct]
Yes

k / R = 7 / 29 = 24.14% · Question Tokens = 12 · P-1 = 610
图像不重叠确认子集：是；核心预算缩减 0 Token；位置均为 0-based。

已选 Semantic　未选 Question　未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	Do 583 / n=1	you 584 / n=1	see 585 / n=1	a 586 / n=1	door 587 / n=1	or 588 / n=1	a 589 / n=1	window 590 / n=1	that 591 / n=1	are 592 / n=1	open 593 / n=1
? 594 / n=1	[newline] 595 / n=1	Answer 596 / n=1	the 597 / n=1	question 598 / n=1	using 599 / n=1	a 600 / n=1	single 601 / n=1	word 602 / n=1	or 603 / n=1	phrase 604 / n=1	. 605 / n=1	
ASSISTANT 606,607,608,609 / n=4												

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

or、door、window、open 已选，而 Do 与 are 未选。输出 Door 而不是 Yes，体现了是非任务的答案类型/格式偏移；Do 是可检验的接收位置，但这也可能是多位置或指令共同作用。

冻结的单组候选：? @[594]；Answer @[596]；ASSISTANT @[606, 607, 608, 609]；Do @[583]；are @[592]；a @[586]

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

ATE / Semantic-k 错误归因 · 错误案例 · 10/16

03567478 | LogicalObj

Are there any TVs or laptops that are on?



Gold
yes

All-Writer [correct]
Yes

Semantic-k [wrong]
No

Question-Last-k [correct]
Yes

Q-Random 20261103 [correct]
Yes

Q-Random 20261107 [correct]
Yes

Q-Random 20261111 [correct]
Yes

原始图片：等比显示，不裁剪

k / R = 8 / 30 = 26.67% · Question Tokens = 13 · P-1 = 611
图像不重叠确认子集：是；核心预算缩减 1 Token；位置均为 0-based。

已选 Semantic | 未选 Question | 未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	Are 583 / n=1	there 584 / n=1	any 585 / n=1	TVs 586,587 / n=2	or 588 / n=1	laptops 589,590,591 / n=3	that 592 / n=1	are 593 / n=1	on 594 / n=1	? 595 / n=1	
[newline] 596 / n=1	Answer 597 / n=1	the 598 / n=1	question 599 / n=1	using 600 / n=1	a 601 / n=1	single 602 / n=1	word 603 / n=1	or 604 / n=1	phrase 605 / n=1	. 606 / n=1	ASSISTANT 607,608,609,610 / n=4	

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

状态词 on 被可行预算缩减删除，any、or、TVs、laptops 已选。不能笼统说数量词或逻辑词未选；更具体的假说是电源状态接收位置丢失，尚待单词补回验证。

冻结的单组候选：? @[595]；Answer @[597]；ASSISTANT @[607, 608, 609, 610]；on @[594]；Are @[583]；there @[584]

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

0481307 | QueryAttr

On which side is the small container?



原始图片：等比显示，不裁剪

Gold
right

All-Writer [correct]
Right

Semantic-k [wrong]
Left

Question-Last-k [correct]
Right

Q-Random 20261103 [correct]
Right

Q-Random 20261107 [wrong]
Left

Q-Random 20261111 [correct]
Right

k / R = 5 / 25 = 20.00% · Question Tokens = 8 · P-1 = 606

图像不重叠确认子集：是；核心预算缩减 0 Token；位置均为 0-based。

已选 Semantic | 未选 Question | 未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	On 583 / n=1	which 584 / n=1	side 585 / n=1	is 586 / n=1	the 587 / n=1	small 588 / n=1	container 589 / n=1	? 590 / n=1	[newline] 591 / n=1	Answer 592 / n=1	the 593 / n=1
question 594 / n=1	using 595 / n=1	a 596 / n=1	single 597 / n=1	word 598 / n=1	or 599 / n=1	phrase 600 / n=1	. 601 / n=1	ASSISTANT 602,603,604,605 / n=4				

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

On、which、side、small、container 全部已选；遗漏 is、the 和问号。左右答案变化不支持“疑问词一定被漏选”的假设；可优先检验问题边界与模板，但本轮未运行。

冻结的单组候选：? @[590]；Answer @[592]；ASSISTANT @[602, 603, 604, 605]；is @[586]；the @[587]

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

ATE / Semantic-k 错误归因 · 错误案例 · 12/16

10763612 | QueryAttr

On which side is the can?



原始图片：等比显示，不裁剪

Gold
right

All-Writer [correct]
Right

Semantic-k [wrong]
Left

Question-Last-k [wrong]
Left

Q-Random 20261103 [wrong]
Left

Q-Random 20261107 [wrong]
Left

Q-Random 20261111 [wrong]
Left

k / R = 0 / 24 = 0.00% · Question Tokens = 7 · P-1 = 605

图像不重叠确认子集：是；核心预算缩减 3 Token；位置均为 0-based。

已选 Semantic | 未选 Question | 未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	On 583 / n=1	which 584 / n=1	side 585 / n=1	is 586 / n=1	the 587 / n=1	can 588 / n=1	? 589 / n=1	[newline] 590 / n=1	Answer 591 / n=1	the 592 / n=1	question 593 / n=1
using 594 / n=1	a 595 / n=1	single 596 / n=1	word 597 / n=1	or 598 / n=1	phrase 599 / n=1	. 600 / n=1	ASSISTANT 601,602,603,604 / n=4					

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

自然 k 被整词后缀对照的可行性约束降到 0，Semantic-k 与 No-Writer 写入集合完全相同。On/which/side 三个核心候选都被预算约束删除；can 同时因固定 STOP 将模态动词与名词罐子混同而未列为核心。这里存在明确的规则设计风险，但不是已验证的补词修复。

冻结的单组候选：? @[589]；Answer @[591]；ASSISTANT @[601, 602, 603, 604]；On @[583]；which @[584]；is @[586]

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

ATE / Semantic-k 错误归因 · 纠正反例 · 13/16

001025435 | ChooseAttr

Is the mud dry or wet?



原始图片：等比显示，不裁剪

Gold
wet

All-Writer [wrong]
Dry

Semantic-k [correct]
Wet

Question-Last-k [correct]
Wet

Q-Random 20261103 [correct]
Wet

Q-Random 20261107 [correct]
Wet

Q-Random 20261111 [correct]
Wet

k / R = 4 / 24 = 16.67% · Question Tokens = 7 · P-1 = 605
图像不重叠确认子集：是；核心预算缩减 0 Token；位置均为 0-based。

已选 Semantic | 未选 Question | 未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	Is 583 / n=1	the 584 / n=1	mud 585 / n=1	dry 586 / n=1	or 587 / n=1	wet 588 / n=1	? 589 / n=1	[newline] 590 / n=1	Answer 591 / n=1	the 592 / n=1	question 593 / n=1

using 594 / n=1	a 595 / n=1	single 596 / n=1	word 597 / n=1	or 598 / n=1	phrase 599 / n=1	. 600 / n=1	ASSISTANT 601,602,603,604 / n=4

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

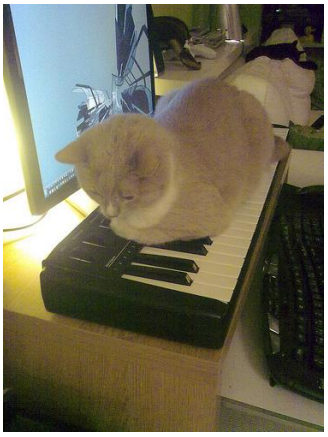
mud、dry、or、wet 已选；冠词、Is、问号及模板未选，Semantic 反而将 Dry 纠正为 Wet。遗漏功能词/模板并不意味着每题都会受损。

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

ATE / Semantic-k 错误归因 · 纠正反例 · 14/16

03678636 | ChooseCat

What type of furniture is not white, the drawer or the chair?



原始图片：等比显示，不裁剪

Gold
drawer

All-Writer [wrong]
Chair

Semantic-k [correct]
Drawer

Question-Last-k [correct]
Drawer

Q-Random 20261103 [correct]
Drawer

Q-Random 20261107 [correct]
Drawer

Q-Random 20261111 [wrong]
Chair

k / R = 11 / 33 = 33.33% · Question Tokens = 16 · P-1 = 614

图像不重叠确认子集：是；核心预算缩减 0 Token；位置均为 0-based。

已选 Semantic　未选 Question　未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	What 583 / n=1	type 584 / n=1	of 585 / n=1	furniture 586,587 / n=2	is 588 / n=1	not 589 / n=1	white 590 / n=1	, 591 / n=1	the 592 / n=1	drawer 593,594 / n=2	
or 595 / n=1	the 596 / n=1	chair 597 / n=1	? 598 / n=1	[newline] 599 / n=1	Answer 600 / n=1	the 601 / n=1	question 602 / n=1	using 603 / n=1	a 604 / n=1	single 605 / n=1	word 606 / n=1	or 607 / n=1
phrase 608 / n=1	. 609 / n=1	ASSISTANT 610,611,612,613 / n=4										

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

否定词 not 实际已选，连同 white、drawer、chair 和 or；Semantic 将 Chair 纠正为 Drawer。这是防止“否定一定被漏选”这一预设解释的重要反例。

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

ATE / Semantic-k 错误归因 · 纠正反例 · 15/16

03539455 | ChooseRel

Is the bag to the right or to the left of the man?



原始图片：等比显示，不裁剪

Gold
left

All-Writer [wrong]
Right

Semantic-k [correct]
Left

Question-Last-k [wrong]
Right

Q-Random 20261103 [wrong]
Right

Q-Random 20261107 [wrong]
Right

Q-Random 20261111 [wrong]
Right

k / R = 8 / 31 = 25.81% · Question Tokens = 14 · P-1 = 612

图像不重叠确认子集：是；核心预算缩减 0 Token；位置均为 0-based。

已选 Semantic　未选 Question　未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	Is 583 / n=1	the 584 / n=1	bag 585 / n=1	to 586 / n=1	the 587 / n=1	right 588 / n=1	or 589 / n=1	to 590 / n=1	the 591 / n=1	left 592 / n=1	of 593 / n=1
the 594 / n=1	man 595 / n=1	? 596 / n=1	[newline] 597 / n=1	Answer 598 / n=1	the 599 / n=1	question 600 / n=1	using 601 / n=1	a 602 / n=1	single 603 / n=1	word 604 / n=1	or 605 / n=1	phrase 606 / n=1
. 607 / n=1	ASSISTANT 608,609,610,611 / n=4											

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

right、left、of、man、bag 及 or 均已选；冠词与 Is 未选。Semantic 从 Right 纠正到 Left，与两道同类关系损害案例共同表明结果具有题目依赖性。

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。
仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。

ATE / Semantic-k 错误归因 · 纠正反例 · 16/16

16958949 | QueryAttr

On which side of the picture is the man?



原始图片：等比显示，不裁剪

Gold
left

All-Writer [wrong]
Right

Semantic-k [correct]
Left

Question-Last-k [correct]
Left

Q-Random 20261103 [correct]
Left

Q-Random 20261107 [correct]
Left

Q-Random 20261111 [correct]
Left

k / R = 5 / 27 = 18.52% · Question Tokens = 10 · P-1 = 608

图像不重叠确认子集：是；核心预算缩减 0 Token；位置均为 0-based。

已选 Semantic | 未选 Question | 未选指令/模板

[space] 581 / n=1	[newline] 582 / n=1	On 583 / n=1	which 584 / n=1	side 585 / n=1	of 586 / n=1	the 587 / n=1	picture 588 / n=1	is 589 / n=1	the 590 / n=1	man 591 / n=1	? 592 / n=1	[newline] 593 / n=1

Answer 594 / n=1	the 595 / n=1	question 596 / n=1	using 597 / n=1	a 598 / n=1	single 599 / n=1	word 600 / n=1	or 601 / n=1	phrase 602 / n=1	. 603 / n=1	ASSISTANT 604,605,606,607 / n=4

上方完整展示 R 词组：词组下方为实际位置与 Subword 数。图像Token和 P-1 不属于可补回位置；逐Token ID与字符Offset见HTML展开表。

只读观察与候选解释（尚无新因果证据）

On、which、side、of、man 已选，picture 因 STOP 排除。Semantic 从 Right 纠正到 Left；提到图片的词不必在每题都直接读图，不能由单个失败推导全部模板/功能词均必要。

因果验证未执行：启动前四卡均有其他任务。没有补词、模板补回或等预算替换的恢复结论。

仅为选定案例，不外推全3000题；历史完整答案和Token集合均未重新生成。